


JAM: A Tiny Flow-based Song Generator with Fine-grained Controllability and Aesthetic Alignment



分享人：宋嘉豪

Contribution

目前所存在的问题

主流歌曲生成模型（DiffRhythm、YuE、LeVo、ACEStep）所存在的问题：

- **模型参数量大**、推理慢、资源消耗大。
- **粗糙的歌词时间控制**：不支持 word-level 的歌词时间对齐，限制了用户对节奏韵律的精确控制。
- **生成歌曲歌词不准确**：生成歌曲的 WER、PER 较高。
- **Duration 控制不佳**：对于全曲、前奏、间奏、尾声等的 duration 控制不佳。

JAM 的贡献

JAM 模型的核心优势：

- **模型参数量小**：以 530M 的参数量达到了非常好的生成效果，推理速度快，节省资源。
- **精细的歌词时间对齐**：通过接收 word-level 和 phoneme-level 的歌词时间输入，实现精确对齐。
- **生成歌词准确性提高**：通过精细的歌词时间对齐能够大幅提升生成歌曲的 WER 和 PER。
- **更好的 duration 控制**：通过精细的歌词时间使得全曲、前奏、间奏、尾声的 duration 预测更好。
- **更严格的模型评估**：采集模型训练完成后新发行的歌曲作为测试集，以免测试数据泄露的问题。
- **音乐审美对齐**：使用 DPO 强化学习算法，以及 SongEval 奖励模型，提升生成歌曲的音乐性。

Model Architecture




Figure 1: A depiction of our proposed architecture and training pipeline.

训练策略（三阶段训练）

- **Pre-training:** 固定样本 duration=90s
- **SFT-training:** 样本 duration = (0, 240s)
- **DPO-training:** 音乐性提升

预训练模型

- **VAE Encoder:** Stable Audio Open
- **VAE Decoder:** DiffRhythm
- **MuQMulan:** 提取 style prompt 和 reference audio 的特征
- **DeepPhonemizer:** 将歌词转化为音标(IPA)
- **SongEval:** 强化学习中的音乐性奖励模型
- **HTDemucs:** 分离人声和伴奏
- **Parakeet:** 将人声转化为歌词并提取 word-level 的时间戳。
- **Qwen2.5-Omni:** 标注歌曲的 genre
- **All-In-One:** 歌曲结构与BPM标注
- **GPT4o:** 歌词时间戳预测对比
- **Audiobox-aesthetic:** 歌曲音乐性评估

创新点

- **Word-Level Temporal Lyric Alignment**
- **Token-Level Duration Control**
- **Aesthetic Preference Alignment**
- **Experimenting with the Duration Predictor**


Word-Level Temporal Lyric Alignment

Lyric: “Should old acquaintance be forget, and never brought to mind ?”

↓ **DeepPhonemizer**

Phonemes:

$$[y_1, y_2, \dots, y_n], \quad y_i = (w_i, t_i^{start}, t_i^{end}), \quad w_i = [p_1, p_2, \dots p_m]$$



Phoneme sequence: P , Length $L = r \times l$

r : upsampling rate, l : length of the latent sequence z_t

Algorithm 1: Word-Level Phoneme Alignment

```
1:  $P = [\text{SONG\_FILLER}] \times L$ 
2: for each  $(w_i, t_i^{start}, t_i^{end})$  do
3:    $p_1, p_2, \dots, p_m = \text{phonemes of } w_i$ 
4:    $\text{start\_frame} = \lfloor t_i^{start} \times f \times r \rfloor$ 
5:    $\text{end\_frame} = \lfloor t_i^{end} \times f \times r \rfloor$ 
6:    $\text{word\_frames} = \text{end\_frame} - \text{start\_frame}$ 
7:    $V = [\text{VOCAL\_FILLER}] \times \text{word\_frames}$ 
8:    $\text{avg\_phoneme\_length} = \lfloor \text{word\_frames} / m \rfloor$ 
9:   for  $j$  in  $[1, \dots, m]$  do
10:     $V[j \times \text{avg\_phoneme\_length}] = p_j$ 
11:   end for
12:    $P[\text{start\_frame} : \text{end\_frame}] = V$ 
13: end for
```

Song Filler: 

用于表示无歌词部分的token，例如前奏，间奏，词间停顿，尾声等。

Vocal Filler: 

用于表示标记词边界，以及词内音素的边界的token。

Aesthetic Preference Alignment

在经过 Pre-training 和 SFT-training 后，JAM-Base 已经具备了生成歌曲的能力，但生成的样本音乐性欠佳，人声呈现电子化特征，整体曲式结构扁平。为了提升生成歌曲音乐性，JAM 以 SongEval 作为奖励模型，使用 DPO 强化学习算法调优 JAM-Base。

DPO-Training Process (iter i)

- **Batched Data Generation**: 首先使用 JAM-base 基于部分训练数据 (20k) 的真实条件生成一批样本，每个条件生成 5 个样本。
- **Preference Dataset Construction**: 使用 SongEval 对每个条件生成的 5 个样本进行打分，选取评分最高和最低的样本作为 win-lose pair。设置阈值为 0.15，筛选出分数差异大于阈值的 win-lose pairs 作为 DPO 训练数据。
- **Preference Optimization**: 计算 DPO 损失函数：

$$\mathcal{L}_{\text{DPO-FM}} = -\mathbb{E}_{t,x^w,x^l} \log \sigma \left(\underbrace{-\beta \left[\|u(x_t^w, t; \theta) - v_t^w\|_2^2 - \|u(x_t^l, t; \theta) - v_t^l\|_2^2 \right]}_{\text{Winning loss}} - \underbrace{\left(\|u(x_t^w, t; \theta_{\text{ref}}) - v_t^w\|_2^2 - \|u(x_t^l, t; \theta_{\text{ref}}) - v_t^l\|_2^2 \right)}_{\text{Losing reference loss}} \right)$$

- **Optimize Model**:

$$\mathcal{L}_{\text{DPO-GT}} = \lambda \mathcal{L}_{\text{FM}} + \mathcal{L}_{\text{DPO-FM}}$$

DPO Loss 解析

- σ : Sigmoid 函数
- 定义 **good_diff** = Winning loss – Winning reference loss, **bad_diff** = Losing loss – Losing reference loss
- 分析 DPO-FM Loss 可知: Loss 与 (good_diff – bad_diff) 呈正向变化。**故要最小化 Loss，就是要使得 good_diff 尽可能小，bad_diff 尽可能大。**
- good_diff 变小意味着 Policy- Model 预测的向量场在逼近好的样本在 Reference-Model 中所预测出的向量场。Bad_diff 变大意味着 Policy- Model 预测的向量场在偏离坏的样本在 Reference-Model 中所预测出的向量场。
- 对于所有 step t 均进行优化，则 Policy- Model 在每个 step 均逼近好样本的向量场，而由于 FM 采样时使用预测出的向量场定义的 ODE 路径，**Policy- Model 实际上学习到了好样本的采样路径。**
- 简单概括的话，DPO 算法让模型通过学习实现采样时走“好样本产生时的路径，避免走坏样本产生时的路径。”

Recent Reinforcement Learning in AIGC

	PPO	DPO	GRPO
优势	通用性强、训练稳定	直接与人类偏好对齐	资源消耗少
劣势	需要同时训练 value model 计算量较大、资源消耗大	需要额外标注数据	训练慢
应用		• Tango2 (24.4, TTA) • TangoFlux (24.12, TTA) • LeVo (25.6, L2S) • Step-Audio-AQAA (25.6, TTA) • DiffRhythm+ (25.7, L2S) • JAM (25.7, L2S)	• F5R-TTS (25.4, TTS) • DanceGRPO (25.5, T2I;T2V) • Omni-R1 (25.5, MLLM) • Flow-GRPO (25.6, T2I)

评估一个项目是否能够使用目前主流的 DPO 和 GRPO 算法进行调优的关键点：

- **有没有好的奖励模型？**：奖励模型能够对齐人类偏好，对于好的样本能够给出明确的信号（方差大）。
- **基座模型是否有一定概率生成好的样本？**：基座模型需要能够生成好的样本，且能够被奖励模型识别到。

Experimenting with the Duration Predictor

在训练时，JAM 使用了非常准确的 word-level 的时间戳，因此在推理时若用户没有提供时间戳，需要考虑如何从条件预测歌词时间戳。论文里进行了三种预测方法的实验：

- 在推理时，直接提供测试样本的真实歌词时间戳。
- 在推理时，使用 GPT4o 基于歌词等条件预测歌词时间戳。
- 在推理时，提供以节拍数标注的歌词时间戳、以及歌曲的 BPM，由此可以转换出歌词时间戳。这种以节拍-歌词对齐的方式被广泛用于音乐家创作过程中：

$$\hat{t} = \underbrace{\lfloor t / (60 / \text{BPM}) \times 4 \rfloor}_{\text{quarter-beat count } n_{\text{beat}}} \times \underbrace{(60 / \text{BPM} / 4)}_{\text{seconds per quarter-beat}}$$

实验结果

Model	MuQ ↑	Audio Aesthetics ↑				SongEval ↑					WER ↓	PER ↓	Genre Acc. ↑	FAD ↓
		CE	CU	PC	PQ	CO	MU	ME	CL	NA				
Oracle	0.7593 ± 0.0964	7.4229 ± 0.5151	7.7046 ± 0.3179	6.2038 ± 0.5051	8.0639 ± 0.4079	4.4163 ± 0.363	4.2929 ± 0.4065	4.4276 ± 0.3935	4.2033 ± 0.4319	4.2026 ± 0.3854	0.1507	0.1011	0.704	0.2038
GPT-Dur	0.6799 ± 0.1341	7.1804 ± 0.8339	7.4392 ± 0.632	5.8459 ± 0.73	7.7356 ± 0.7092	4.0568 ± 0.6313	3.9432 ± 0.6271	4.0436 ± 0.6993	3.798 ± 0.6627	3.8267 ± 0.6202	0.3701	0.3204	0.6437	0.2441
Direct-Quant	0.7597 ± 0.0995	7.4164 ± 0.4969	7.6905 ± 0.3318	6.2041 ± 0.5072	8.0367 ± 0.4187	4.3879 ± 0.4042	4.2622 ± 0.4394	4.391 ± 0.4401	4.1624 ± 0.4755	4.1587 ± 0.4397	0.2076	0.1441	0.6842	0.2091

Table 9: Duration prediction results.

启示

- 精确的歌词时间戳预测对 JAM 模型生成效果提升非常显著。
- 基于节奏的歌词时间戳预测能够有效提升生成效果。

Experiment Results

Model	MuQ $\uparrow$	Audio Aesthetics $\uparrow$				SongEval $\uparrow$					WER $\downarrow$	PER $\downarrow$	Genre Acc. $\uparrow$	FAD $\downarrow$
		CE	CU	PC	PQ	CO	MU	ME	CL	NA				
DiffRhythm _{full}	0.5208 ± 0.1192	6.0448 ± 0.6483	7.3126 ± 0.2526	5.1088 ± 0.7276	7.6276 ± 0.2904	2.7975 ± 0.4621	2.3547 ± 0.4813	2.6141 ± 0.5031	2.5135 ± 0.4495	2.4467 ± 0.4454	0.3481	0.2643	0.6667	0.4384
ACE-Step	0.444 ± 0.1349	7.0067 ± 0.5669	7.3583 ± 0.3848	6.3117 ± 0.4417	7.5851 ± 0.4952	3.5305 ± 0.5017	3.2593 ± 0.497	3.3927 ± 0.5452	3.3079 ± 0.5186	3.1703 ± 0.5031	0.4067	0.342	0.6194	0.2296
LeVo	0.5234 ± 0.1241	7.3783 ± 0.5372	7.7794 ± 0.3126	6.1773 ± 0.7251	8.1794 ± 0.3578	3.6343 ± 0.4489	3.41 ± 0.463	3.4997 ± 0.4945	3.3815 ± 0.4572	3.3086 ± 0.4378	0.4586	0.3819	0.66	0.5336
Yue	0.705 ± 0.1418	6.8928 ± 0.7895	7.3289 ± 0.3909	6.1234 ± 0.9002	7.6234 ± 0.4441	3.5072 ± 0.5379	3.208 ± 0.5462	3.401 ± 0.5796	3.2361 ± 0.5439	3.1633 ± 0.5198	0.5119	0.4263	0.702	0.2411
JAM	0.7593 ± 0.0964	7.4229 ± 0.5151	7.7046 ± 0.3179	6.2038 ± 0.5051	8.0639 ± 0.4079	4.4163 ± 0.363	4.2929 ± 0.4065	4.4276 ± 0.3935	4.2033 ± 0.4319	4.2026 ± 0.3854	0.1507	0.1011	0.704	0.2038

Table 3: A cross-genre comparative evaluation of JAM and baseline song generation models on JAME.

Model	MuQ $\uparrow$	Audio Aesthetics $\uparrow$				SongEval $\uparrow$					WER $\downarrow$	PER $\downarrow$	Genre Acc. $\uparrow$	FAD $\downarrow$
		CE	CU	PC	PQ	CO	MU	ME	CL	NA				
SFT	0.7473 ± 0.0803	7.0006 ± 0.5392	7.3541 ± 0.3927	6.4831 ± 0.3993	7.5915 ± 0.5166	3.4159 ± 0.4896	3.0851 ± 0.5198	3.2712 ± 0.5634	3.0871 ± 0.5167	3.0525 ± 0.4812	0.167	0.1131	0.708	0.1479
DPO _{Round-1}	0.7598 ± 0.082	7.1529 ± 0.5288	7.5063 ± 0.317	6.435 ± 0.4196	7.7666 ± 0.4397	3.8753 ± 0.4468	3.6202 ± 0.4935	3.8235 ± 0.5122	3.5762 ± 0.4857	3.5444 ± 0.4662	0.1629	0.1106	0.72	0.1223
DPO _{Round-2}	0.7616 ± 0.0916	7.3851 ± 0.4778	7.6699 ± 0.2986	6.2778 ± 0.4953	8.0082 ± 0.3925	4.2504 ± 0.4059	4.0892 ± 0.445	4.2465 ± 0.4428	4.0052 ± 0.4693	3.9903 ± 0.4336	0.1579	0.1066	0.696	0.1527
DPO _{Round-2-GT}	0.7673 ± 0.0889	7.3769 ± 0.4699	7.6902 ± 0.2652	6.3188 ± 0.49	8.0297 ± 0.3537	4.247 ± 0.3889	4.0724 ± 0.4379	4.2432 ± 0.427	4.0024 ± 0.4486	3.9814 ± 0.425	0.1553	0.1083	0.736	0.1455
DPO _{Round-3}	0.7593 ± 0.0964	7.4229 ± 0.5151	7.7046 ± 0.3179	6.2038 ± 0.5051	8.0639 ± 0.4079	4.4163 ± 0.363	4.2929 ± 0.4065	4.4276 ± 0.3935	4.2033 ± 0.4319	4.2026 ± 0.3854	0.1507	0.1011	0.704	0.2038
DPO _{Round-3-GT}	0.767 ± 0.0886	7.4159 ± 0.4706	7.7113 ± 0.3023	6.2573 ± 0.4764	8.0554 ± 0.3928	4.4102 ± 0.3468	4.2767 ± 0.3844	4.4185 ± 0.3799	4.1875 ± 0.4184	4.1787 ± 0.382	0.1472	0.1009	0.704	0.1791

Table 4: Comparing SFT and different DPO loss functions across iterative rounds.

Setup

- **Train Dataset**: around 1 million (54000 hours) English songs.
- **Machine**: 8 * H800
- **DPO Round**: 3
- **CFG**: Multi-Condition CFG
- **Style Embedding**: 随机选取训练样本的 30s 片段的 MuQMulan 作为 embedding.

Stage	Global Batch Size	Learning Rate	Steps	Grad. Accum.
Pretraining	32	7.5×10^{-5}	750K	1
SFT	32	7.5×10^{-5}	250K	1
DPO Round i	8	5×10^{-7}	20K	4

Table 1: Training hyper-parameters.

Model	Architecture	Training Data	Model Size
YuE	AR LM + AR Decoder	135k hours	7B + 1B
AceStep	Flow Matching	100k hours	3.5B
LeVo	AR LM + Diffusion Decoder	110k hours	2B + 0.7B
DiffRhythm	Flow Matching	60k hours	1.1B
Ours	Flow Matching	54k hours	0.53B

Table 2: Comparison of full-song generation models.

Comments

以下是我对 JAM 这个工作的一些评价：

- 核心贡献是证明了 Word-Level 的歌词时间对齐可以大幅提升音乐性和WER。但这种好的效果需要用户提供精确的歌词时间戳。
- 文章通过实验验证了使用基于节拍数来预测真实歌词时间戳的有效性，这种节拍数-歌词对齐的方式非常符合真实场景下歌曲创作的形式，这让 JAM 的使用更加便利，对于专业用户来说，提供节拍-歌词对齐信息而不是连续的时间戳更加符合创作习惯。
- 文章并没有研究推理时的 Duration Predictor，所以如何在用户没有提供时间戳或节拍信息时去预测一个好的时间戳仍然是一个很大的挑战。
- 总得来说，JAM 揭示了在精细的歌词时间信息下，小模型、小数据集所能达到的高上限效果，但代价是推理时也需要精细的歌词时间戳，需要研究 Duration Predictor。

Thanks For Listening!